Фиксированный контекстный учитель для AARTM: инициализация и KL-согласование

Станислав Енягин

Аннотация

Исследуется перенос семантической информации в тематическую модель AARTM при малом объёме данных. Замороженный MiniLM кодирует фрагменты документов; их мягкая кластеризация задаёт распределения тем для слов. Эти распределения используются для инициализации и KL-согласования AARTM без новых обучаемых параметров. На пяти коллекциях document-completion перплексия снижается в среднем на 7,40% в 45 парных сравнениях. На 99 049 документах arXiv растёт обучающая PMI, однако общего улучшения внешней NPMI на малых коллекциях нет.

1 Введение

Тематические модели описывают документы распределениями по темам, а темы — распределениями по словам [1]. Рассматриваемая модель AARTM дополняет аддитивную регуляризацию [2] локальным вниманием к соседним словам. На малых коллекциях ей может не хватать данных для выявления семантических связей.

В работе предлагается использовать предобученную языковую модель как фиксированного учителя AARTM. Распределения тем, полученные из контекстных представлений фрагментов, задают инициализацию и KL-регуляризатор. Перенос знаний в тематические модели исследовался ранее [3]; здесь проверяется его применение к AARTM без дообучения кодировщика. Методы сравниваются по перплексии, когерентности и времени работы.

2 Постановка задачи

Пусть заданы корпус документов D, словарь V и число тем T. Требуется найти матрицу $\Phi_{wt} = p(t \mid w)$, согласованную с фиксированным учителем $Q_{wt} = q(t \mid w)$. Учитель строится из контекстных представлений обучающих документов. Его распределения используются для инициализации Φ и KL-регуляризации:

$$\widehat{\Phi} \in \underset{\substack{\Phi_{wt}\geq 0 \\ \sum_t \Phi_{wt}=1}}{\arg\min} \left[\mathcal{L}_{\text{AARTM}}(\Phi) + \lambda \sum_{w \in V} \mathrm{KL}(q_w \| \Phi_w) \right], \tag{1}$$

где $\mathcal{L}_{\text{AARTM}}$ — базовый критерий обучения AARTM, λ — коэффициент регуляризации. Кодировщик и Q при обучении не меняются. Необходимо оценить, улучшает ли такое согласование качество модели и какой вклад в результат вносят инициализация и KL.

3 Метод

В AARTM распределение тем для позиции i уточняется по соседним словам:

$$\theta_{it} = \sum_{j \in \mathcal{C}(i)} a_{ij} \Phi_{w_j t}, \qquad r_{it} = \frac{\Phi_{w_i t}\theta_{it}/\pi_t}{\sum_{s=1}^{T} \Phi_{w_i s}\theta_{is}/\pi_s}.$$

Здесь $\mathcal{C}(i)$ — окно внутри документа, a_{ij} — фиксированные нормированные веса внимания, π_t — текущая оценка частоты темы.

MiniLM [4] кодирует неперекрывающиеся фрагменты c обучающих документов длиной до 100 слов. Нормированные векторы e_c кластеризуются методом KMeans (на arXiv — MiniBatchKMeans). По нормированным центрам μ_t вычисляется распределение тем фрагмента, затем — распределение тем для слова:

$$q(t \mid c) = \frac{\exp(e_c^\top \mu_t/\tau)}{\sum_{s=1}^{T} \exp(e_c^\top \mu_s/\tau)}, \qquad Q_{wt} = \frac{\sum_c n_{cw} q(t \mid c) + \varepsilon}{\sum_{s=1}^{T} \left(\sum_c n_{cw} q(s \mid c) + \varepsilon\right)}.$$

Здесь $\tau = 0.05$, n_{cw} — число вхождений слова w во фрагмент c, $\varepsilon > 0$ — сглаживание.

Матрица Q используется для инициализации:

$$\Phi^{(0)} = \mathrm{norm}_t\big(0.05\Phi^{\mathrm{rand}} + 0.95Q + \varepsilon\big),$$

где norm_t нормирует строки по темам, а Φ^{rand} — случайное начальное приближение. При обновлении AARTM добавляется поправка по градиенту KL-штрафа из (1) с $\lambda = 0.1$. Матрица Q остаётся фиксированной.

Алгоритм обучения. После построения Q и инициализации $\Phi^{(0)}$ на каждой итерации:

1. Вычисляются локальные распределения θ_{it} и назначения r_{it}.
2. Назначения суммируются по словам; транспонированный оператор внимания учитывает влияние на соседние позиции.
3. К базовому обновлению добавляется отрицательный градиент $\lambda\,\mathrm{KL}(Q\|\Phi)$ с коэффициентами AARTM. Отрицательные значения обрезаются, строки нормируются по темам; частоты тем обновляются как $\sum_i r_{it}$.

После заданного числа итераций возвращается Φ. Для базовой AARTM используются случайная инициализация и $\lambda = 0$.

Свойства. При ненулевой массе строки нормировка сохраняет её неотрицательность и единичную сумму. KL-штраф равен нулю при совпадении распределений. Учитель не добавляет обучаемых параметров; хранение Q и вычисление KL-поправки требуют $O(|V|T)$ памяти и операций соответственно. Улучшение внешних метрик и глобальная сходимость не гарантируются.

4 Эксперименты

Сравниваются базовая AARTM и AARTM+Q с фиксированным учителем.

На BBC, TechCrunch, PubMed, AG News и четырёх категориях 20 Newsgroups используются выборки по 10, 30 и 50 документов и три seed. Для BBC задаются 5 тем, для AG News и 20NG — 4, для TechCrunch и PubMed — 10. Обучение длится 100 итераций; окно внимания включает по пять соседних токенов с каждой стороны.

Качество предсказания оценивается по перплексии восстановления каждого пятого слова новых документов (document completion). Учитываются только слова обучающего словаря. PMI рассчитывается по обучающим документам, внешняя NPMI — по отдельным референсным документам; в обоих случаях используются десять наиболее вероятных слов темы. Для каждой пары запусков сначала вычисляется относительное снижение PPL, затем результаты усредняются.

В 45 парных сравнениях completion PPL снижается в среднем на 7.40%, улучшение получено в 42 парах. Обучающая PPL уменьшается на 7.91%, обучающая PMI возрастает на 2.28. Внешняя NPMI при этом меняется в среднем на -0.0027 и улучшается в 17 из 45 пар (таблица 1, рисунок 1).

Таблица 1: Среднее снижение completion PPL и изменение внешней NPMI для AARTM+Q относительно AARTM, по девять пар на корпус.

Корпус	Снижение PPL, %	ΔNPMI
BBC	6.53	+0.0322
20NG (4 кат.)	9.15	+0.0508
AG News	11.87	-0.0342
TechCrunch	6.41	-0.0657
PubMed	3.06	+0.0032

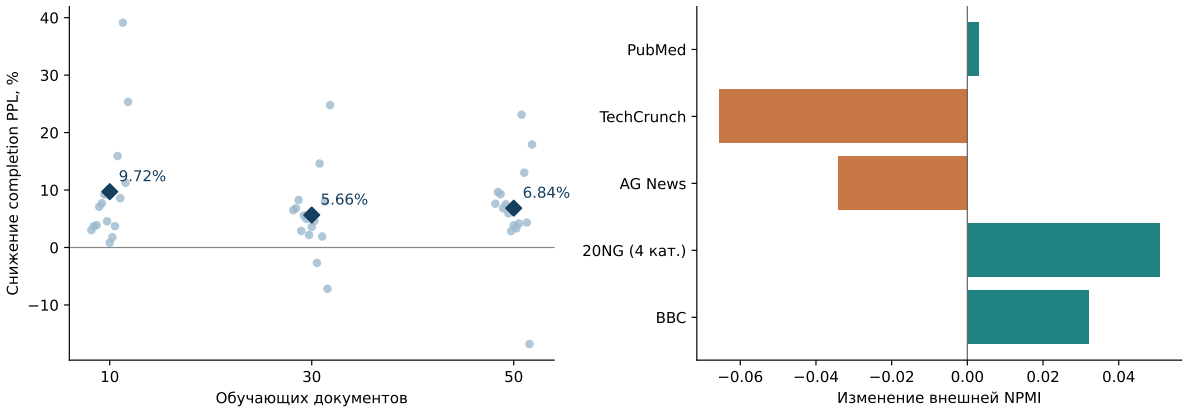


Рис. 1: Слева — снижение completion PPL при разных размерах обучения: точки показывают отдельные пары, ромбы — средние. Справа — среднее изменение внешней NPMI по корпусам.

Абляции на BBC, TechCrunch и PubMed охватывают 27 пар. Полный метод снижает completion PPL на 5.34%, одна инициализация — на 5.27%, только KL — на 1.14%, переставленный учитель — на 0.90%. Основную часть выигрыша даёт инициализация; дополнительный эффект KL невелик.

На arXiv используются 99 049 документов после фильтрации и общий словарь из 12 662 слов. Рассматриваются 50, 100, 200, 300 и 500 тем, по четыре seed и 30 итераций AARTM. Обучающая PMI AARTM+Q выше базовой AARTM во всех 20 парах. При 500 темах отношение средних PMI равно 2.03, снижение обучающей PPL — 2.42%.

Таблица 2: Обучающая PMI на arXiv: среднее $\pm$ выборочное стандартное отклонение по четырём seed.

T	AARTM	AARTM+Q	FASTopic	CombinedTM+MiniLM
50	0.564 ± 0.009	0.679 ± 0.010	0.009 ± 0.277	-3.887 ± 0.701
100	0.599 ± 0.025	0.751 ± 0.012	-4.948 ± 0.791	-5.451 ± 0.539
200	0.550 ± 0.072	0.761 ± 0.016	-6.653 ± 0.673	-6.298 ± 0.330
300	0.443 ± 0.049	0.710 ± 0.025	-7.392 ± 0.458	-4.077 ± 0.560
500	0.271 ± 0.028	0.550 ± 0.057	-8.062 ± 0.442	-1.019 ± 0.057

FASTopic [5] обучен 30 эпох, CombinedTM [6] — 100 эпох с MiniLM и общим словарём. При этих настройках AARTM+Q имеет наибольшую обучающую PMI. Однако увеличение обучения FASTopic до 200 эпох в одном запуске повысило его PMI с -5.759 до -0.198; сходимость CombinedTM отдельно не проверялась. Результат относится к указанным настройкам и обучающим метрикам; тестовой оценки на arXiv нет.

Время AARTM+Q включает построение Q из готовых векторов и обучение, время альтернатив — обучение. Первичное кодирование не учитывается, поэтому ускорение полного процесса не установлено. CSV, настройки и код пересчёта опубликованы в `https://github.com/Estanislavo/llm_tm_kl`.

Список литературы

[1] David M. Blei, Andrew Y. Ng, and Michael I. Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022, 2003.

[2] Konstantin Vorontsov and Anna Potapenko. Additive regularization of topic models. *Machine Learning*, 101:303–323, 2015.

[3] Alexander Hoyle, Pranav Goel, and Philip Resnik. Improving neural topic models using knowledge distillation. In *Proceedings of EMNLP*, pages 1752–1771, 2020.

[4] Sentence Transformers. all-MiniLM-L6-v2: Model card. Hugging Face, `https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2`.

[5] Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. FASTopic: Pretrained transformer is a fast, adaptive, stable, and transferable topic model. In *Advances in Neural Information Processing Systems*, volume 37, 2024.

[6] Federico Bianchi, Silvia Terragni, and Dirk Hovy. Pre-training is a hot topic: Contextualized document embeddings improve topic coherence. In *Proceedings of ACL-IJCNLP: Short Papers*, pages 759–766, 2021.