Фиксированный контекстный учитель для AARTM: инициализация и KL-согласование

Станислав Енягин

Аннотация

Исследуется перенос семантической информации в тематическую модель AARTM при малом объёме данных. Замороженный MiniLM кодирует фрагменты документов; их мягкая кластеризация задаёт распределения тем для слов. Эти распределения используются для инициализации и KL-согласования AARTM без новых обучаемых параметров. На пяти коллекциях document-completion перплексия снижается в среднем на 7,40% в 45 парных сравнениях. На 99 049 документах arXiv растёт обучающая PMI, однако общего улучшения внешней NPMI на малых коллекциях нет.

Ключевые слова. Тематическое моделирование; AARTM; контекстные эмбеддинги; фиксированный учитель; KL-регуляризация; перплексия; когерентность.

Основные результаты.

- Распределения тем для слов строятся из контекстных представлений фрагментов.
- Один фиксированный учитель задаёт инициализацию и KL-согласование AARTM.
- На пяти малых коллекциях completion PPL снижается в среднем на 7,40%; внешний NPMI не показывает общего роста.

1 Введение

Тематические модели описывают документы смесями тем, а темы — распределениями по словам [1]. При обучении на небольшой коллекции эти распределения оцениваются по ограниченному числу вхождений и совместных встречаемостей слов. В работе рассматривается способ дополнить такие наблюдения семантической информацией предобученной языковой модели. Базовой моделью служит AARTM, которая сочетает аддитивную регуляризацию [2] с локальным вниманием к соседним словам. Наша цель — улучшить её предсказания без дообучения внешнего кодировщика и изменения набора обучаемых параметров AARTM.

Внешняя семантика уже используется в нескольких семействах тематических моделей. ETM задаёт вероятности слов через эмбеддинги слов и тем [3]. CombinedTM включает контекстное представление документа во вход вариационной сети [4]. В FASTopic фиксированные представления документов связываются с обучаемыми представлениями тем и слов посредством оптимального транспорта [5]. Эти подходы различаются тем, на каком этапе и в какой форме семантические представления участвуют в обучении.

Контекст можно учитывать и на уровне отдельных вхождений слов. CWTM использует контекстные представления слов в нейронной тематической модели [6]; Contextual-Top2Vec на их основе выделяет темы и соответствующие им участки документов [7]. Мы используем представления фрагментов исходного текста и агрегируем их тематические назначения по словам словаря. Так получается матрица $Q = (q(t \mid w))$, которую можно передать AARTM как фиксированное семантическое ограничение. Агрегация сохраняет сведения о контекстах употребления, но усредняет различные значения одного слова.

По способу переноса знаний работа близка к дистилляции нейронных тематических моделей, предложенной Hoyle и соавторами [8]. В их методе BERT-учитель задаёт распределения по словам для восстановления документов. Здесь учитель задаёт распределения по темам для каждого слова. Различается и способ его применения: одна матрица Q используется сначала для инициализации AARTM, затем для KL-регуляризации её параметров. Вклад работы состоит в этом построении и его экспериментальной проверке на AARTM.

Предлагаемый метод, AARTM+Q, строит учителя только по обучающим документам. После построения Q кодировщик больше не участвует в обновлениях тематической модели. Дополнительные затраты приходятся на кодирование фрагментов, кластеризацию и хранение матрицы размера $|V| \times T$. KL-согласование также может уменьшать разреженность тематических распределений. Поэтому наряду с полным методом мы рассматриваем более простой вариант, использующий только семантическую инициализацию.

Эксперимент должен установить, улучшает ли учитель восстановление скрытых слов и какая часть эффекта связана с инициализацией, а какая — с KL. На пяти корпусах используются 10, 30 и 50 обучающих документов и три начальных состояния генератора случайных чисел. Методы сравниваются попарно на одних и тех же данных; качество предсказания оценивается по перплексии, согласованность наиболее вероятных слов тем — по PMI и внешней NPMI. Среднее снижение document-completion PPL составляет 7,40%, хотя внешняя NPMI систематически не растёт. Отдельная серия на 99 049 документах arXiv исследует зависимость обучающей PMI от числа тем и сопоставляет AARTM+Q с FASTopic и CombinedTM.

2 Постановка задачи

Пусть $D_{\text{tr}} = \{d_1, \ldots, d_m\}$ — обучающая коллекция, а $d = (w_{d0}, \ldots, w_{d,L_d-1})$ — последовательность токенов документа. По D_{tr} строятся словарь V и частоты слов $f_w > 0$; число тем T задано. Для оценивания выделены непересекающиеся с обучением коллекции D_{ref} и D_{test}: первая используется для внешней когерентности, вторая — для восстановления слов. Частотная матрица $X \in \mathbb{N}_0^{m \times |V|}$ содержит счётчики слов. Порядок токенов и границы документов нужны для вычисления локального внимания.

В пределах одного корпуса предполагается независимость документов; зависимости между токенами учитываются через их окружение. Модель задаёт условное распределение слова по локальному контексту. Метки категорий используются только при отборе документов. Предобработка, ограничения длины и число тем одинаковы для сравниваемых методов. Качество восстановления оценивается на словах из V с отдельным учётом покрытия тестового словаря.

Искомая матрица $\Phi \in \mathcal{S} = \{A \in \mathbb{R}_+^{|V| \times T} : \sum_t A_{wt} = 1\}$ содержит вероятности $p(t \mid w)$. Соответствующие вероятности слов внутри темы $B_{wt} = p(w \mid t)$ получаются частотным взвешиванием. При фиксированных весах внимания a_{ij} модель задаётся соотношениями

$$B_{wt}(\Phi) = \frac{f_w \Phi_{wt}}{\sum_v f_v \Phi_{vt}}, \quad \theta_{it}(\Phi) = \sum_{j \in \mathcal{C}(i)} a_{ij} \Phi_{w_j t}, \quad p_\Phi(w \mid \mathcal{C}(i)) = \sum_t B_{wt}(\Phi)\theta_{it}(\Phi). \tag{1}$$

Множество $\mathcal{C}(i)$ содержит до пяти соседних позиций с каждой стороны в том же документе; $a_{ii} = 0$, $a_{ij} \geq 0$, $\sum_j a_{ij} = 1$. До нормировки $a_{ij} \propto 0.6(1-0.6)^{|i-j|}$ при $1 \leq |i-j| \leq 5$. Рассматриваются позиции с непустым контекстом и темы с положительной частотной массой.

Для обучения используется локальный составной критерий

$$\mathcal{L}_{\text{loc}}(\Phi) = -\sum_{d \in D_{\text{tr}}} \sum_{i=0}^{L_d - 1} \log p_\Phi(w_{di} \mid \mathcal{C}_d(i)). \tag{2}$$

Контексты перекрываются, поэтому этот критерий не является логарифмом совместного правдоподобия документа. Согласование с учителем задаётся штрафом $K(\Phi; Q) = \sum_w \mathrm{KL}(q_w \| \Phi_w)$, где строки Q — распределения тем для слов. Матрица Q строится по D_{tr} и остаётся фиксированной вместе с кодировщиком.

Гиперпараметры выбираются на предварительной серии и затем фиксируются. Контроль основан на повторном отборе обучающих документов при общих D_{ref} и D_{test}. Основной показатель — перплексия восстановления скрытых слов в D_{test}; дополнительно оцениваются NPMI на D_{ref}, покрытие словаря и время работы. Искомое решение — допустимая матрица $\widehat{\Phi}$. Для её получения применяется конечная EM-подобная процедура AARTM с инициализацией из Q и KL-поправкой; нахождение глобального минимума не гарантируется. Задача регуляризованного оценивания имеет вид

$$\widehat{\Phi} \in \operatorname*{arg\,min}_{\Phi \in \mathcal{S}} \left[\mathcal{L}_{\text{loc}}(\Phi) + \lambda \sum_{w \in V} \sum_{t=1}^{T} q_{wt} \log \frac{q_{wt}}{\Phi_{wt}} \right], \qquad \lambda = 0.1. \tag{3}$$

3 Вычислительный эксперимент

3.1 Цель эксперимента

Основной вопрос — улучшает ли контекстный учитель восстановление скрытых слов по сравнению с AARTM. Для этого модели обучаются на одинаковых документах с общим словарём и неизменным локальным вниманием. Абляции проверяют вклад инициализации, дополнительный эффект KL и зависимость результата от соответствия строк Q словам. Внешняя NPMI позволяет сопоставить предсказательный эффект с когерентностью тем, а серия arXiv — проследить изменение обучающей PMI при увеличении числа тем.

3.2 Данные и организация контроля

Малая серия включает пять открытых англоязычных корпусов: BBC News [9], TechCrunch [10], тексты статей PubMed Central из Common Pile [11], AG News [12] и 20 Newsgroups [13]. Исходные локальные выгрузки содержат соответственно 2225, 10 265, 1200, 127 600 и 3641 записей до удаления дубликатов. Для 20NG используются категории `comp.graphics`, `rec.sport.hockey`, `sci.space` и `talk.politics.misc`.

После удаления пустых текстов и точных дубликатов документы перемешиваются с seed 20260911. Первые 200 документов образуют D_{ref}, следующие 20 используются для предварительной настройки, ещё 40 — для итогового восстановления слов. Из оставшихся документов отбираются обучающие выборки размера 10, 30 и 50 с seed 10, 11 и 12. На BBC, AG News и 20NG отбор сбалансирован по категориям; на TechCrunch и PubMed он случайный. Используются 5 тем для BBC, 4 для AG News и 20NG, 10 для TechCrunch и PubMed. Всего сравниваются $5 \times 3 \times 3 = 45$ пар AARTM/AARTM+Q. Разные обучающие выборки могут пересекаться, поэтому эти пары не образуют 45 независимых статистических повторений. Обучающие, референсные и тестовые документы друг с другом не пересекаются.

Тексты малых коллекций переводятся в нижний регистр, символы вне `a--z` заменяются пробелами. Затем применяются NLTK-токенизация, стемминг Porter и удаление токенов, совпавших с английским списком стоп-слов. Словарь строится заново для каждой обучающей выборки. Учитель получает фрагменты исходного текста; счётчики их слов вычисляются тем же препроцессором и проецируются на обучающий словарь. Диапазоны числа токенов и размера словаря приведены в таблице 1.

Таблица 1: Число тем, диапазоны размера словаря и числа обучающих токенов на малых коллекциях. Покрытие тестовых токенов усреднено по девяти выборкам; его различия следует учитывать при сравнении PPL.

Корпус	T	$\lvert V\rvert$	Токены	Покрытие
BBC	5	885–3160	1801–12107	0.667
20NG (4 кат.)	4	365–3968	542–15037	0.528
AG News	4	179–814	232–1288	0.332
TechCrunch	10	1445–3947	3732–20450	0.762
PubMed	10	3178–9476	21477–143447	0.825

Для большой серии используются заголовки и аннотации arXiv из Kaggle metadata snapshot [14]. Резервуарным отбором с seed 2026 выбраны 100 000 записей. После фильтрации остаются 99 049 документов, 9 827 939 токенов и словарь из 12 662 слов. Извлекаются латинские слова в нижнем регистре длиной не менее двух символов; английские стоп-слова удаляются до стемминга Porter. Сохраняется не более 512 токенов на документ при мини-

мальной длине 20 токенов. Порог частоты слова равен 20, верхняя граница размера словаря — 50 000. Все модели используют один подготовленный корпус и словарь. Для учителя берутся первые 100 000 фрагментов прошедших фильтр документов, поэтому документы могут вносить разный вклад в Q. В этой серии оцениваются только обучающие метрики.

3.3 Построение учителя и алгоритм обучения

Каждый обучающий текст разбивается на неперекрывающиеся фрагменты c длиной до 100 слов. Кодировщик `all-MiniLM-L6-v2` из Sentence Transformers [15, 16] преобразует их в нормированные 384-мерные векторы e_c. Его параметры фиксированы, предельная длина входа составляет 256 word pieces; более длинные входы усекаются. На малых коллекциях векторы кластеризуются KMeans с `n_init=10`, на arXiv — MiniBatchKMeans. По нормированным центрам μ_t вычисляются мягкие назначения фрагментов и распределения учителя:

$$q(t \mid c) = \frac{\exp(e_c^\top \mu_t/\tau)}{\sum_s \exp(e_c^\top \mu_s/\tau)}, \qquad q_{wt} = \frac{\sum_c n_{cw} q(t \mid c) + \epsilon}{\sum_s [\sum_c n_{cw} q(s \mid c) + \epsilon]}, \quad \tau = 0.05. \tag{4}$$

n_{cw} — число вхождений слова w после проекции на словарь. Все вероятности q_{wt} сохраняются без отсечения малых значений. Начальная матрица AARTM задаётся смесью учителя и случайного распределения:

$$\Phi^{(0)} = \mathrm{norm}_t \left(0.05\Phi^{\text{rand}} + 0.95Q + 10^{-8}\right), \tag{5}$$

где norm_t нормирует строку по темам.

Обновление AARTM вычисляет локальные тематические смеси, апостериорные назначения токенов и достаточные статистики. К нему добавляется поправка по градиенту $K(\Phi; Q) = \sum_w \mathrm{KL}(q_w \| \Phi_w)$ с направлением KL от учителя к модели. После отсечения отрицательных значений строки нормируются. На малых корпусах выполняется 100 EM-подобных обновлений при $\lambda = 0.1$, контексте по пять токенов с каждой стороны, $\gamma = 0.6$ и одном проходе внимания. Матрица Q остаётся неизменной.

На BBC, TechCrunch и PubMed проведены абляции на 27 общих сочетаниях размера и seed. Рассматриваются только инициализация ($\lambda = 0$), только KL при случайной инициализации, а также полный метод с перестановкой строк учителя. Базовая AARTM использует ту же реализацию с нулевыми весами инициализации и KL.

На arXiv используются $T \in \{50, 100, 200, 300, 500\}$ и seed 42–45. Потоковая CUDA-реализация AARTM выполняет до 30 итераций с `tol=0.001`, блоками по 50 000 токенов, 10 блоками на обновление и коэффициентом обновления 0.1. Параметры учителя совпадают с малой серией; размер пакета равен 4096 для MiniBatchKMeans и 256 для кодировщика. Численная эквивалентность этой реализации и JAX-реализации малых серий отдельно не проверялась.

FASTopic 1.0.1 обучен 30 эпох с размером пакета 1024 при $T = 50$ и 4096 при остальных T. CombinedTM 2.6.1 с декодером ProdLDA обучен 100 эпох с пакетом 256. Оба метода получают нормированные MiniLM-эмбеддинги документов с учётом ограничения длины входа кодировщика. CombinedTM адаптирован к общему словарю из 12 662 слов и MiniLM, поэтому его конфигурация отличается от авторской. Большие серии выполнены на RTX 3070 Ti Laptop с 8 ГБ памяти, малая JAX-серия — на CPU.

3.4 Метрики и агрегирование

Перплексия. Для N обучающих токенов перплексия равна

$$\mathrm{PPL}_{\text{tr}} = \exp\left[-\frac{1}{N}\sum_i \log g\left(\sum_t B_{w_i t}\theta_{it}\right)\right], \tag{6}$$
$$g_{\text{small}}(x) = x + 10^{-12}, \qquad g_{\text{arXiv}}(x) = \max(x, 10^{-12}).$$

Для оценки на новых документах используется document completion [17]. Токены с индексами $i \equiv 0 \pmod 5$ (нумерация с нуля) скрываются до исключения слов вне словаря. По оставшимся токенам при фиксированном B оценивается θ_d. Применяются сглаживание $\widetilde{B}_{wt} = 0.9999 B_{wt} + 0.0001/|V|$, начальное приближение $\theta_{dt}^{(0)} = 1/T$ и 40 обновлений

$$z_{dwt}^{(k)} = n_{dw}^{O} \frac{\widetilde{B}_{wt}\theta_{dt}^{(k)}}{\sum_s \widetilde{B}_{ws}\theta_{ds}^{(k)}}, \qquad \theta_{dt}^{(k+1)} = \frac{0.1 + \sum_w z_{dwt}^{(k)}}{0.1T + \sum_w n_{dw}^{O}}. \tag{7}$$

При $M_H = \sum_{d,w \in V} n_{dw}^{H}$ итоговая метрика равна

$$\mathrm{PPL}_{\mathrm{comp}} = \exp\left[-\frac{1}{M_H} \sum_{d,w \in V} n_{dw}^{H} \log \max\left(\sum_t \widetilde{B}_{wt}\theta_{dt}^{(40)}, 10^{-30} \right) \right]. \tag{8}$$

В формулу входят только скрытые слова из V. Покрытием называется доля всех тестовых токенов, принадлежащих V. В среднем она составляет 0.332 на AG News и 0.825 на PubMed. Таким образом, оценка характеризует восстановление известной части словаря.

Когерентность. Пусть $p_D(w)$ — доля документов с w, а $p_D(u,v)$ — доля с обоими словами. Для каждого топика выбираются десять слов с наибольшим B_{wt} [18]. Метрики пар слов равны

$$\mathrm{PMI}_D(u,v) = \log\left(\frac{p_D(u,v)}{p_D(u)p_D(v)} + 10^{-12} \right), \qquad \mathrm{NPMI}_D(u,v) = \frac{\log \frac{p_D(u,v)}{p_D(u)p_D(v)}}{-\log p_D(u,v)}. \tag{9}$$

Величины усредняются по 45 неупорядоченным парам слов каждой темы, затем по темам. Для NPMI [19] принимается значение -1 при $p_D(u,v) = 0$ и 0 при $p_D(u,v) = 1$. В PMI нулевая совместная встречаемость даёт вклад $\log(10^{-12}) \simeq -27.63$. PMI рассчитывается на обучающих документах; внешняя NPMI малых серий — на 200 документах D_{ref}.

Парные изменения. Для пары j базовой AARTM (A) и варианта с учителем (Q) вычисляются

$$\begin{aligned} g_j &= 100 \frac{\mathrm{PPL}_{A,j} - \mathrm{PPL}_{Q,j}}{\mathrm{PPL}_{A,j}}, \qquad \bar{g} = \frac{1}{n}\sum_j g_j, \\ \Delta C_j &= C_{Q,j} - C_{A,j}, \qquad s(x) = \sqrt{\frac{1}{n-1}\sum_j (x_j - \bar{x})^2}. \end{aligned} \tag{10}$$

Положительный g_j соответствует снижению перплексии. Усредняются относительные изменения внутри пар, что позволяет объединять результаты с разными словарями. Приводимые стандартные отклонения $s(x)$ выборочные; они описывают разброс запусков, а не доверительные интервалы.

3.5 Результаты на малых коллекциях и абляции

Учитель снижает completion PPL в 42 из 45 пар, в среднем на 7.4047%. Обучающая PPL уменьшается на 7.9066% (45/45), обучающая PMI возрастает на 2.2789 (38/45). Среднее снижение completion PPL положительно на каждом из пяти корпусов (таблица 2). По размеру обучения наибольший эффект наблюдается при десяти документах (рисунок 1).

Изменение внешней NPMI зависит от корпуса: положительный эффект получен на BBC, 20NG и PubMed, отрицательный — на AG News и TechCrunch. Средняя разница равна -0.002731, улучшение наблюдается в 17/45 парах. На AG News наибольшему снижению

completion PPL сопутствует уменьшение внешней когерентности. Следовательно, улучшение предсказания известных слов не сопровождается общим улучшением тематических списков по NPMI.

Таблица 2: Парное снижение completion PPL (10) и изменение внешней NPMI (9), по девять пар на корпус. SD — выборочное стандартное отклонение. Среднее снижение PPL положительно на всех корпусах, изменение NPMI имеет разный знак.

Корпус	$\bar{g}$, %	SD, п.п.	Победы	$\overline{\Delta\text{NPMI}}$
BBC	6.53	2.47	9/9	+0.0322
20NG (4 кат.)	9.15	8.16	8/9	+0.0508
AG News	11.87	17.27	7/9	-0.0342
TechCrunch	6.41	1.84	9/9	-0.0657
PubMed	3.06	1.28	9/9	+0.0032

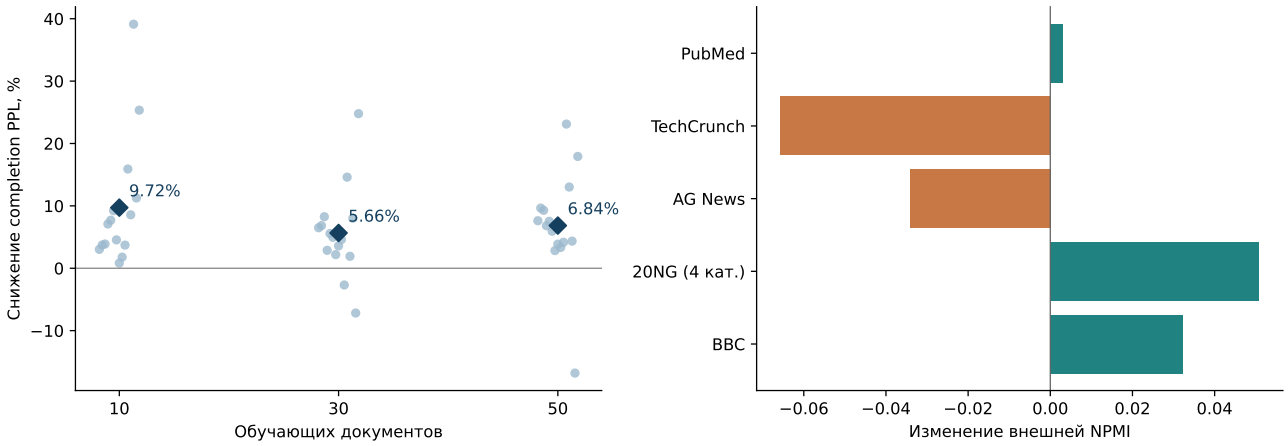


Рис. 1: Слева: снижение completion PPL по формуле (10), по 15 пар на размер обучения; круги — отдельные пары, ромбы — средние. Средний эффект максимален при десяти документах. Справа: изменение внешней NPMI, усреднённое по девяти парам каждого корпуса. Направление изменения когерентности зависит от корпуса.

Абляции показывают, что основная часть выигрыша связана с инициализацией (таблица 3). На 27 общих парах полный метод снижает completion PPL на 5.3357%, только инициализация — на 5.2676%. Дополнительный средний эффект KL составляет около 0.068 процентного пункта; его статистическая значимость не установлена. При случайной инициализации один KL даёт 1.1404%, а перестановка строк учителя оставляет 0.9025% выигрыша. Это указывает на важность соответствия учителя словам. Плотный KL при этом уменьшает разреженность Φ.

Таблица 3: Снижение completion PPL (10) на BBC, TechCrunch и PubMed, 27 общих пар. Инициализация сохраняет большую часть выигрыша полного метода.

Вариант	$\bar{g}$, %	SD, п.п.	Победы
Инициализация + KL	5.34	2.47	27/27
Только инициализация	5.27	2.63	27/27
Только KL	1.14	1.36	22/27
Переставленный учитель	0.90	1.21	20/27

3.6 arXiv и сопоставление с альтернативами

На arXiv обучающая PMI AARTM+Q выше базовой AARTM во всех 20 парах (таблица 4, рисунок 2). При $T = 500$ отношение средних равно $0.5499/0.2709 \simeq 2.03$, а среднее парное снижение обучающей PPL составляет 2.42%. При $T = 100$ PPL уменьшается в трёх из четырёх пар, при остальных T — во всех четырёх.

Таблица 4: Обучающие PPL (6) и PMI (9) на arXiv: среднее $\pm$ выборочное SD по четырём seed; $\bar{g}$ определено в (10). Учитель повышает среднюю PMI при каждом числе тем.

T	PPL AARTM	PPL AARTM+Q	$\bar{g}$, %	PMI AARTM	PMI AARTM+Q
50	1050.45 ± 4.69	1045.22 ± 1.76	0.50	0.564 ± 0.009	0.679 ± 0.010
100	906.59 ± 0.73	903.42 ± 3.13	0.35	0.599 ± 0.025	0.751 ± 0.012
200	785.28 ± 2.36	778.75 ± 1.40	0.83	0.550 ± 0.072	0.761 ± 0.016
300	723.83 ± 2.55	717.19 ± 0.36	0.92	0.443 ± 0.049	0.710 ± 0.025
500	664.03 ± 1.97	647.99 ± 0.80	2.42	0.271 ± 0.028	0.550 ± 0.057

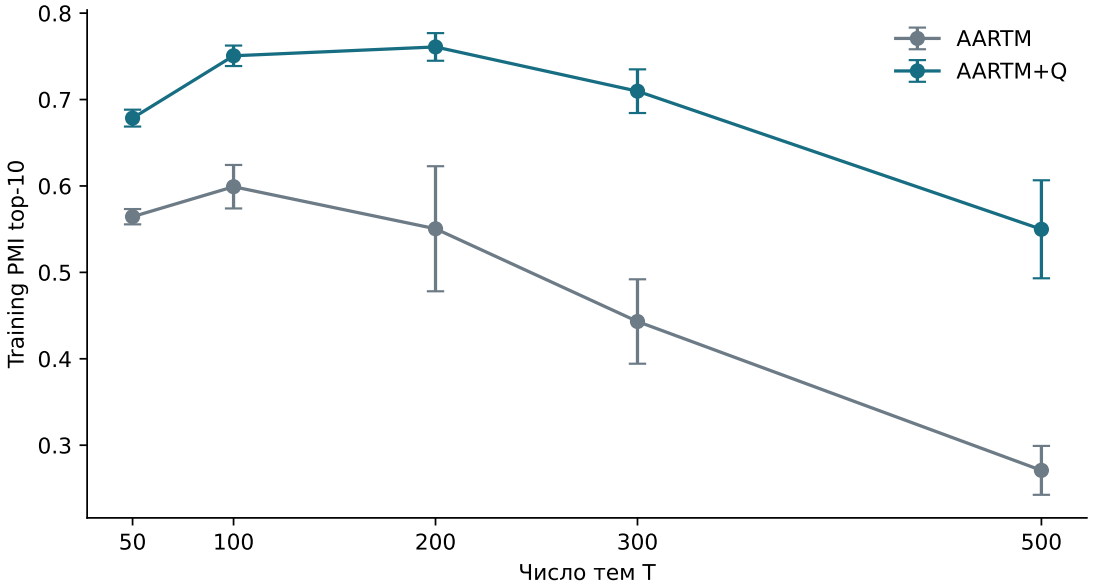


Рис. 2: Обучающая PMI десяти наиболее вероятных слов темы по формуле (9) на 99 049 документах arXiv. Точки — средние четырёх seed, отрезки — выборочные стандартные отклонения. AARTM+Q превосходит базовую AARTM по этой метрике при каждом числе тем.

AARTM+Q также имеет наибольшую обучающую PMI среди трёх сравниваемых конфигураций при всех T (таблица 5). Для интерпретации этого результата существенно число эпох FASTopic: в дополнительном запуске с $T = 100$ и seed 42 увеличение бюджета с 30 до 200 эпох повысило PMI с -5.7588 до -0.1984. Следовательно, короткая серия недообучает этот метод. Сходимость CombinedTM отдельно не проверялась, а его настройка с MiniLM отличается от авторской. Отрицательные значения PMI усиливаются штрафом за пары слов без совместных появлений. Такое сравнение характеризует заданный протокол, но не лучшие достижимые результаты альтернатив.

Таблица 5: Обучающая PMI (9) на arXiv, среднее $\pm$ выборочное SD по четырём seed. AARTM+Q имеет наибольшую PMI при заданных бюджетах обучения.

T	AARTM+Q	FASTopic	CombinedTM+MiniLM
50	0.679 ± 0.010	0.009 ± 0.277	-3.887 ± 0.701
100	0.751 ± 0.012	-4.948 ± 0.791	-5.451 ± 0.539
200	0.761 ± 0.016	-6.653 ± 0.673	-6.298 ± 0.330
300	0.710 ± 0.025	-7.392 ± 0.458	-4.077 ± 0.560
500	0.550 ± 0.057	-8.062 ± 0.442	-1.019 ± 0.057

Таблица 6: Время в секундах, среднее $\pm$ выборочное SD. Для AARTM+Q учтены построение Q и обучение, для остальных — обучение; первичное кодирование исключено. Соотношение времён меняется с числом тем.

T	AARTM+Q	FASTopic	CombinedTM+MiniLM
50	192 ± 146	505 ± 8	1479 ± 368
100	420 ± 271	223 ± 112	2064 ± 16
200	632 ± 327	662 ± 71	2020 ± 148
300	1178 ± 458	958 ± 133	1861 ± 136
500	2321 ± 90	1754 ± 137	2525 ± 632

В таблице 6 для AARTM+Q измерены построение Q из готовых эмбеддингов и обучение, для FASTopic и CombinedTM — обучение. Подготовка данных, первичное кодирование и оценивание исключены; полное время кодирования учителя не зафиксировано. При $T = 500$ AARTM+Q занимает в среднем 2321.4 с, базовая AARTM — 2292.5 с. Для seed 43 и 45 время взято из повторных измерений, показатели качества — из исходных запусков. Эти измерения не позволяют установить ускорение полного процесса от исходного текста; кроме того, бюджеты обучения не обеспечивают одинаковой степени сходимости моделей.

3.7 Обсуждение результатов

Полученные результаты связывают предсказательный выигрыш AARTM+Q прежде всего с семантической инициализацией. Дополнительный эффект KL на малых коллекциях невелик, а изменение внешней NPMI неоднородно. На arXiv наблюдается рост обучающей PMI, однако качество на новых документах в этой серии не оценивалось. Следующие проверки должны включать отложенную выборку arXiv, сравнение сошедшихся моделей и единое измерение времени от исходного текста.

Код малой модели, исходные строки результатов, конфигурации и манифесты разбиений доступны в `https://github.com/Estanislavo/llm_tm_kl`. Таблицы и рисунки пересчитываются из опубликованных CSV. Точное переобучение исторических серий ограничено отсутствием зафиксированных ревизий датасетов и контрольной суммы исходного снимка arXiv; полная потоковая инфраструктура и веса большой серии в репозиторий не включены. Инструкции по запуску и сведения об окружении приведены в документации репозитория.

Использование ИИ. При подготовке текста, поиске литературы и разработке кода использовались инструменты генеративного ИИ. Экспериментальные результаты проверены по исходным записям запусков.

Список литературы

[1] David M. Blei, Andrew Y. Ng, and Michael I. Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022, 2003.

[2] Konstantin Vorontsov and Anna Potapenko. Additive regularization of topic models. *Machine Learning*, 101:303–323, 2015.

[3] Adji B. Dieng, Francisco J. R. Ruiz, and David M. Blei. Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453, 2020.

[4] Federico Bianchi, Silvia Terragni, and Dirk Hovy. Pre-training is a hot topic: Contextualized document embeddings improve topic coherence. In *Proceedings of ACL-IJCNLP: Short Papers*, pages 759–766, 2021.

[5] Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. FASTopic: Pretrained transformer is a fast, adaptive, stable, and transferable topic model. In *Advances in Neural Information Processing Systems*, volume 37, 2024.

[6] Zheng Fang, Yulan He, and Rob Procter. CWTM: Leveraging contextualized word embeddings from BERT for neural topic modeling. In *Proceedings of LREC-COLING*, pages 4273–4286, 2024.

[7] Dimo Angelov and Diana Inkpen. Topic modeling: Contextual token embeddings are all you need. In *Findings of EMNLP*, pages 13528–13539, 2024.

[8] Alexander Hoyle, Pranav Goel, and Philip Resnik. Improving neural topic models using knowledge distillation. In *Proceedings of EMNLP*, pages 1752–1771, 2020.

[9] SetFit. BBC News: Dataset card. Hugging Face, `https://huggingface.co/datasets/SetFit/bbc-news`.

[10] abhilash88. TechCrunch Articles: Dataset card. Hugging Face, `https://huggingface.co/datasets/abhilash88/techcrunch-articles`.

[11] Common Pile. PubMed: Article-text dataset card. Hugging Face, `https://huggingface.co/datasets/common-pile/pubmed`.

[12] fancyzhx. AG News: Dataset card. Hugging Face, `https://huggingface.co/datasets/fancyzhx/ag_news`.

[13] SetFit. 20 Newsgroups: Dataset card. Hugging Face, `https://huggingface.co/datasets/SetFit/20_newsgroups`.

[14] Cornell University. arXiv Dataset: Metadata snapshot. Kaggle, `https://www.kaggle.com/datasets/Cornell-University/arxiv`.

[15] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019.

[16] Sentence Transformers. all-MiniLM-L6-v2: Model card. Hugging Face, `https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2`.

[17] Hanna M. Wallach, Iain Murray, Ruslan Salakhutdinov, and David Mimno. Evaluation methods for topic models. In *Proceedings of ICML*, 2009.

[18] David Newman, Jey Han Lau, Karl Grieser, and Timothy Baldwin. Automatic evaluation of topic coherence. In *Proceedings of NAACL-HLT*, pages 100–108, 2010.

[19] Gerlof Bouma. Normalized (pointwise) mutual information in collocation extraction. Author manuscript, 2009.