Фиксированный контекстный учитель для AARTM: инициализация и KL-согласование

Станислав Енягин

23 октября 2026 года

Аннотация

Исследуется перенос семантической информации в тематическую модель AARTM при малом объёме данных. Замороженный MiniLM кодирует фрагменты документов; их мягкая кластеризация задаёт распределения тем для слов. Эти распределения используются для инициализации и KL-согласования AARTM без новых обучаемых параметров. На пяти коллекциях document-completion перплексия снижается в среднем на 7,40% в 45 парных сравнениях. На 99 049 документах arXiv растёт обучающая PMI, однако общего улучшения внешней NPMI на малых коллекциях нет.

Ключевые слова. Тематическое моделирование; AARTM; контекстные эмбеддинги; фиксированный учитель; KL-регуляризация; перплексия; когерентность.

Основные результаты.

- Распределения тем для слов строятся из контекстных представлений фрагментов.
- Один фиксированный учитель задаёт инициализацию и KL-согласование AARTM.
- На пяти малых коллекциях completion PPL снижается в среднем на 7,40%; внешний NPMI не показывает общего роста.

1 Введение

Работа посвящена улучшению тематической модели AARTM с помощью фиксированного контекстного учителя. Цель состоит в переносе семантической информации предобученного кодировщика в тематические распределения без его дообучения и без добавления обучаемых параметров внимания. Такая постановка полезна при анализе небольших новостных, научных и специализированных коллекций, где совместных встречаемостей слов недостаточно для устойчивого оценивания тем.

Тематическая модель описывает документ смесью тем, а тему распределением по словам; классический пример представляет LDA [1]. В ARTM к критерию согласия с данными добавляются регуляризаторы, задающие желаемые свойства решения [2]. Рассматриваемая в проекте AARTM использует локальное внимание: тематическое распределение позиции зависит от соседних слов. Контекстными эмбеддингами называются векторные представления текста, учитывающие его окружение; в работе кодируются фрагменты исходных документов. Когерентность характеризует совместную встречаемость наиболее вероятных слов темы, а перплексия оценивает качество предсказания слов. Эти свойства не тождественны.

Основная идея состоит в однократном построении матрицы $Q = (q(t \mid w))$ из эмбеддингов фрагментов. Мягкие назначения фрагментов тематическим кластерам агрегируются по вхождениям слов. Полученный учитель определяет начальное состояние AARTM и дополнительный KL-штраф при обучении. В отличие от изолированного кодирования слов, фрагмент сохраняет информацию об употреблении слова, хотя последующая агрегация в одну строку Q усредняет его разные значения.

Использование векторной семантики в тематическом моделировании имеет несколько направлений. ETM параметризует темы через эмбеддинги слов и тем [3]; CombinedTM подаёт контекстное представление документа в вариационную сеть [4]; FASTopic обучает связи документов, тем и слов с использованием оптимального транспорта [5]. Эти методы позволяют вводить внешнюю семантику, но используют другие модели и критерии обучения. CWTM учитывает контекстные представления слов [6], а Contextual-Top2Vec выделяет темы и их фрагменты на основе токенных эмбеддингов [7]. Они также не сводятся к регуляризации фиксированной матрицей целей для AARTM.

Ближайший по идее переноса знаний предшественник — дистилляция нейронных тематических моделей у Hoyle и соавторов [8]: BERT-учитель задаёт распределения по словам для восстановления документов. Поэтому новизна настоящей работы не состоит в использовании учителя или KL-дивергенции как таковых. Исследуемое отличие — построение фиксированного распределения *тем для каждого слова* из контекста фрагментов и совместное использование этого распределения для инициализации и регуляризации существующей AARTM. Сильная простая альтернатива внутри этой постановки — та же инициализация без дальнейшего KL-согласования.

Для достижения цели решаются три задачи: построить Q только по обучающим документам; сопоставить полный метод с AARTM и абляциями на одинаковых выборках; проверить предсказательное качество, когерентность и измеренное время. Преимущество подхода — сохранение набора обучаемых параметров базовой модели; издержки — построение учителя, хранение Q размера $|V| \times T$ и возможное уменьшение разреженности. Отсутствие дообучения кодировщика само по себе не гарантирует ускорения всего вычислительного процесса.

Эксперимент проверяет восстановление скрытых слов на пяти корпусах при 10, 30 и 50 обучающих документах и трёх seed. Серия на 99 049 документах arXiv оценивает обучающую PMI при разных числах тем. Парный протокол фиксирует данные, абляции разделяют эффекты инициализации и KL. Наблюдается снижение document-completion PPL на 7,40% в среднем без систематического роста внешней NPMI. Сравнение с FASTopic и CombinedTM ограничено сохранёнными конфигурациями.

2 Постановка задачи

Дано. Обучающая коллекция $D_{\text{tr}} = \{d_1, \ldots, d_m\}$, где $d = (w_{d0}, \ldots, w_{d,L_d-1})$ — последовательность токенов. Словарь V и частоты $f_w > 0$ строятся только по D_{tr}; T — заданное число тем. Дополнительно даны непересекающиеся множества документов D_{ref} для внешней когерентности и D_{test} для восстановления слов. Частотная матрица $X \in \mathbb{N}_0^{m\times|V|}$ задаёт счётчики слов, а порядок токенов и границы документов сохраняются для внимания.

Предположения и ограничения. Документы рассматриваются как наблюдения одной предметной коллекции; независимость документов используется как рабочее допущение, но не проверена. Модель задаёт локальное условное распределение слова по окружению; независимость токенов внутри документа не предполагается. Разные корпуса не считаются одной генеральной совокупностью. Метки категорий служат только для сбалансированного отбора, а не для обучения. Ограничения длины, фильтрация и число тем фиксируются до сравнения методов; неизвестные тестовые слова исключаются из PPL с отдельным указанием покрытия.

Класс моделей. Искомый параметр $\Phi \in \mathcal{S} = \{A \in \mathbb{R}_+^{|V|\times T} : \sum_t A_{wt} = 1\}$ хранит $p(t \mid w)$. Он отличается от распределения слов внутри темы $B_{wt} = p(w \mid t)$. При фиксированных весах внимания a_{ij} модель имеет вид

$$B_{wt}(\Phi) = \frac{f_w \Phi_{wt}}{\sum_v f_v \Phi_{vt}}, \quad \theta_{it}(\Phi) = \sum_{j\in\mathcal{C}(i)} a_{ij}\Phi_{w_j t}, \quad p_\Phi(w \mid \mathcal{C}(i)) = \sum_t B_{wt}(\Phi)\theta_{it}(\Phi). \tag{1}$$

Здесь $\mathcal{C}(i)$ содержит до пяти соседей с каждой стороны в том же документе; $a_{ii} = 0$, $a_{ij} \geq 0$, $\sum_j a_{ij} = 1$. До нормировки $a_{ij} \propto 0.6(1-0.6)^{|i-j|}$ при $1 \leq |i-j| \leq 5$. Требуются непустой контекст и положительная частотная масса каждого используемого топика. Число параметров Φ совпадает с AARTM.

Критерии. Согласие с обучением описывается локальным составным критерием

$$\mathcal{L}_{\text{loc}}(\Phi) = -\sum_{d\in D_{\text{tr}}} \sum_{i=0}^{L_d-1} \log p_\Phi(w_{di} \mid \mathcal{C}_d(i)). \tag{2}$$

Перекрывающиеся контексты не задают независимые наблюдения; произведение локальных вероятностей не объявляется совместным порождающим распределением документа. Семантический критерий $K(\Phi; Q) = \sum_w \text{KL}(q_w \| \Phi_w)$ использует фиксированную строково-стохастическую матрицу Q, построенную только по D_{tr}. Энкодер и Q не оптимизируются совместно с Φ.

Контроль и результат. Гиперпараметры выбраны на предварительной серии, затем зафиксированы. Используется повторный отбор обучения с общими reference/test, а не k-fold контроль. Основной внешний критерий — completion PPL на скрытых токенах D_{test}; дополнительные — NPMI на D_{ref}, покрытие словаря, память и время. Уменьшение обучающей ошибки не заменяет внешнюю проверку. Решение — допустимая матрица $\widehat{\Phi}$; алгоритм — конечная EM-подобная процедура AARTM с инициализацией из Q и KL-поправкой. Она не гарантирует нахождения глобального минимума. Формальная задача регуляризованного оценивания записывается как

$$\widehat{\Phi} \in \arg\min_{\Phi\in\mathcal{S}} \left[\mathcal{L}_{\text{loc}}(\Phi) + \lambda \sum_{w\in V}\sum_{t=1}^{T} q_{wt} \log \frac{q_{wt}}{\Phi_{wt}}\right], \qquad \lambda = 0.1. \tag{3}$$

3 Вычислительный эксперимент

3.1 Цель и проверяемые гипотезы

Проверяется, помогает ли фиксированный контекстный учитель улучшить AARTM при сохранении данных, словаря и локального внимания. Гипотеза H1: на малых коллекциях AARTM+Q снижает document-completion PPL относительно AARTM. H2: выигрыш зависит от содержательного соответствия строк Q словам; поэтому он должен уменьшаться после их перестановки. H3: KL даёт дополнительный эффект относительно одной инициализации. H4: увеличение обучающей PMI на arXiv сохраняется при разных T. Отдельно проверяется, сопровождается ли предсказательный выигрыш ростом внешней NPMI. Это описательные сравнения на фиксированной сетке; формальные уровни значимости не заявляются.

3.2 Данные и организация контроля

Использованы открытые англоязычные коллекции BBC News [9], TechCrunch [10], тексты статей PubMed Central из Common Pile [11], AG News [12] и четыре категории 20 Newsgroups [13]. В локальных исходных файлах сохранены соответственно 2225, 10 265, 1200, 127 600 и 3641 записей; это размеры локальных выгрузок до удаления дубликатов, а не объёмы обучения. PubMed содержит тексты статей, не только аннотации. Для 20NG выбраны `comp.graphics`, `rec.sport.hockey`, `sci.space`, `talk.politics.misc`.

Пустые тексты и точные дубликаты удаляются. Для каждого корпуса фиксированная перестановка с seed 20260911 выделяет первые 200 документов для reference, следующие 20 для предварительной настройки и следующие 40 для итогового document completion; обучение отбирается из оставшейся части. Проверены SHA-256 манифесты: train, reference и evaluation не пересекаются. Обучающих документов 10, 30 или 50; seed отбора и инициализации 10, 11, 12. BBC, AG News и 20NG отбираются с балансировкой категорий, TechCrunch и PubMed случайно. Число тем: 5 для BBC, 4 для AG News и 20NG, 10 для TechCrunch и PubMed. Получаются $5 \times 3 \times 3 = 45$ пар AARTM/AARTM+Q. Размеры 10/30/50 и разные seed могут давать пересекающиеся выборки; 45 пар не являются 45 независимыми повторениями.

Для малых коллекций применяется штатный препроцессор проекта: нижний регистр, замена символов вне `a--z` пробелами, NLTK-токенизация, Porter stemming, затем удаление слов, совпавших с английским списком stopwords. Этот порядок сохранён в опубликованном исходнике. Словарь строится только по обучению, без единого общего словаря между корпусами или размерами. Фрагменты для учителя берутся из исходного текста; их счётчики проецируются тем же препроцессором на обучающий словарь. Таблица 1 показывает фактические диапазоны размеров признакового пространства.

Таблица 1: Малые коллекции: число тем, диапазоны размера словаря и числа обучающих токенов; покрытие словаря на тестовых документах. Большое различие покрытий ограничивает сопоставимость абсолютной PPL.

Корпус	T	$\lvert V \rvert$	Токены	Покрытие
BBC	5	885–3160	1801–12107	0.667
20NG (4 кат.)	4	365–3968	542–15037	0.528
AG News	4	179–814	232–1288	0.332
TechCrunch	10	1445–3947	3732–20450	0.762
PubMed	10	3178–9476	21477–143447	0.825

Большая коллекция — заголовки и аннотации arXiv из Kaggle metadata snapshot [14]. Из ис-

ходного файла резервуарным отбором с seed 2026 выбраны 100 000 записей; после фильтрации сохранены 99 049 документов, 9 827 939 токенов и 12 662 слова. Токенизация: латинские слова в нижнем регистре длиной не менее двух символов, удаление английских stopwords до стемминга Porter, не более 512 токенов на документ; минимальная длина документа 20 токенов. Словарь включает слова с частотой не менее 20 при верхней границе 50 000. Общий подготовленный корпус и словарь используются всеми сравниваемыми моделями. Учитель ограничен первыми 100 000 фрагментами прошедших фильтр документов, что не гарантирует равного вклада всех документов. Отложенной тестовой серии arXiv в этих результатах нет.

3.3 Построение учителя и алгоритм обучения

Неперекрывающиеся фрагменты c содержат до 100 слов исходного текста. Замороженный `all-MiniLM-L6-v2` семейства Sentence Transformers [15, 16] выдаёт нормированные 384-мерные векторы e_c. Предельная длина входа кодировщика — 256 word pieces; 100 слов не гарантируют отсутствия усечения. На малых коллекциях применяется KMeans с `n_init=10`, на arXiv — MiniBatchKMeans. Центры μ_t нормируются; затем

$$q(t \mid c) = \frac{\exp(e_c^\top \mu_t/\tau)}{\sum_s \exp(e_c^\top \mu_s/\tau)}, \qquad q_{wt} = \frac{\sum_c n_{cw} q(t \mid c) + \epsilon}{\sum_s [\sum_c n_{cw} q(s \mid c) + \epsilon]}, \quad \tau = 0.05. \tag{4}$$

n_{cw} — число вхождений слова w в фрагмент после проекции на словарь. Матрица плотная; отсечение до 30% тем не используется. Инициализация задаётся как

$$\Phi^{(0)} = \mathrm{norm}_t \left(0.05\Phi^{\mathrm{rand}} + 0.95Q + 10^{-8}\right), \tag{5}$$

где norm_t нормирует строку по темам.

Далее вычисляются локальные тематические смеси, апостериорные назначения токенов и достаточные статистики AARTM. К базовому обновлению добавляется поправка, использующая градиент $K(\Phi; Q) = \sum_w \mathrm{KL}(q_w \| \Phi_w)$; после отсечения отрицательных значений строки нормируются. Направление KL — от учителя к модели. На малых корпусах выполняется 100 EM-подобных обновлений, $\lambda = 0.1$, контекст по пять токенов с каждой стороны, $\gamma = 0.6$, один проход внимания. Ни Q, ни кодировщик в этих обновлениях не меняются. Точный порядок вычислений и численные стабилизаторы сохранены в `code/aartm_q/semantic_aartm.py`; глобальная сходимость из постановки (3) не следует.

Абляции выполняются на BBC, TechCrunch и PubMed, то есть на 27 общих сочетаниях размера и seed: только инициализация ($\lambda = 0$); только KL (случайная инициализация); инициализация и KL с перестановкой строк учителя. Базовая AARTM использует ту же реализацию при нулевых весах учителя. Исходные конфигурации в репозитории сохранены без правок и содержат также исторические варианты; в опубликованные таблицы отобраны только AARTM и фиксированные контекстные учителя.

На arXiv сравниваются $T \in \{50, 100, 200, 300, 500\}$, seed 42–45. AARTM и AARTM+Q используют потоковую CUDA-реализацию: максимум 30 итераций, `tol=0.001`, блоки по 50 000 токенов, 10 блоков на обновление, коэффициент обновления 0.1. Параметры Q совпадают с малыми сериями, MiniBatchKMeans использует batch 4096, кодирование фрагментов — batch 256. Численное тождество потоковой CUDA и малой JAX-реализации не установлено, поэтому результаты рассматриваются как две экспериментальные серии.

FASTopic 1.0.1 обучен 30 эпох: batch 1024 при $T = 50$, 4096 при остальных T. CombinedTM 2.6.1 (декодер ProdLDA) обучен 100 эпох с batch 256. Оба используют нормированные MiniLM-эмбеддинги исходных документов; это отличается от фрагментного учителя. Вход целого документа также ограничен длиной энкодера. CombinedTM с общим словарём 12 662 слова и

MiniLM — адаптация, а не воспроизведение авторской конфигурации. Большие серии выполнены на RTX 3070 Ti Laptop, 8 ГБ; малая JAX-серия — на CPU. Версии библиотек малой серии и revision MiniLM зафиксированы в `data/configs/small_environment.json`.

3.4 Метрики и агрегирование

Перплексия. Для N обучающих токенов training PPL определяется как

$$\begin{gathered}\mathrm{PPL}_{\mathrm{tr}} = \exp\left[-\frac{1}{N}\sum_i \log g\left(\sum_t B_{w_i t}\theta_{it}\right)\right], \\ g_{\mathrm{small}}(x) = x + 10^{-12}, \qquad g_{\mathrm{arXiv}}(x) = \max(x, 10^{-12}).\end{gathered} \tag{6}$$

Она характеризует обучение, не обобщение. Основная малая метрика следует подходу document completion [17]: в каждом тестовом документе токены с индексами $i \equiv 0 \pmod 5$ (нумерация с нуля) скрываются до исключения OOV. По оставшимся токенам при фиксированном B выводится θ_d; скрытая часть в выводе не участвует. Используется сглаживание $\widetilde{B}_{wt} = 0.9999 B_{wt} + 0.0001/|V|$, $\theta_{dt}^{(0)} = 1/T$ и 40 обновлений

$$z_{dwt}^{(k)} = n_{dw}^{O}\frac{\widetilde{B}_{wt}\theta_{dt}^{(k)}}{\sum_s \widetilde{B}_{ws}\theta_{ds}^{(k)}}, \qquad \theta_{dt}^{(k+1)} = \frac{0.1 + \sum_w z_{dwt}^{(k)}}{0.1T + \sum_w n_{dw}^{O}}. \tag{7}$$

При $M_H = \sum_{d,w\in V} n_{dw}^{H}$ итоговая метрика равна

$$\mathrm{PPL}_{\mathrm{comp}} = \exp\left[-\frac{1}{M_H}\sum_{d,w\in V} n_{dw}^{H}\log\max\left(\sum_t \widetilde{B}_{wt}\theta_{dt}^{(40)}, 10^{-30}\right)\right]. \tag{8}$$

Она условна на обучающем словаре. Покрытие в исходном протоколе — доля всех тестовых токенов, входящих в V, а не отдельная доля только скрытых позиций. На AG News среднее покрытие 0.332, на PubMed 0.825; поэтому выигрыш не переносится автоматически на все слова новых документов.

Когерентность. Пусть $p_D(w)$ — доля документов с w, а $p_D(u,v)$ — доля с обоими словами. Для каждого топика выбираются десять слов с наибольшим B_{wt} [18]. Метрики пар слов равны

$$\mathrm{PMI}_D(u,v) = \log\left(\frac{p_D(u,v)}{p_D(u)p_D(v)} + 10^{-12}\right), \qquad \mathrm{NPMI}_D(u,v) = \frac{\log\frac{p_D(u,v)}{p_D(u)p_D(v)}}{-\log p_D(u,v)}. \tag{9}$$

Обе величины усредняются по 45 неупорядоченным парам слов каждой темы и по темам. В NPMI [19] при $p_D(u,v) = 0$ берётся -1, при $p_D(u,v) = 1$ берётся 0. В PMI нулевая совместная встречаемость даёт $\log(10^{-12}) \simeq -27.63$. Training PMI вычисляется на обучении; внешняя NPMI малых серий — на 200 reference-документах. Эти оценки не взаимозаменяемы.

Парные эффекты и разброс. Для каждой общей пары j базовой AARTM (A) и варианта (Q) сначала вычисляется

$$\begin{gathered}g_j = 100\frac{\mathrm{PPL}_{A,j} - \mathrm{PPL}_{Q,j}}{\mathrm{PPL}_{A,j}}, \qquad \bar{g} = \frac{1}{n}\sum_j g_j, \\ \Delta C_j = C_{Q,j} - C_{A,j}, \qquad s(x) = \sqrt{\frac{1}{n-1}\sum_j (x_j - \bar{x})^2}.\end{gathered} \tag{10}$$

Положительный g_j означает улучшение. Проценты не получаются из отношения общих средних абсолютной PPL по разным словарям. Все SD в этом документе выборочные; они описывают разброс сохранённых запусков и не являются доверительными интервалами.

3.5 Результаты на малых коллекциях и абляции

На 45 основных парах среднее снижение completion PPL составляет 7.4047%, улучшение получено в 42 парах. Training PPL снижается на 7.9066% (45/45), training PMI возрастает на 2.2789 (38/45). Внешняя NPMI меняется в среднем на -0.002731 и улучшается в 17/45 парах. Таблица 2 показывает, что средний предсказательный эффект положителен на всех корпусах, тогда как внешняя когерентность меняется в обе стороны. Наибольший средний выигрыш completion PPL получен на AG News, где NPMI снижается.

Таблица 2: Снижение completion PPL по формуле (10) и изменение внешней NPMI по формуле (9). По девять пар на корпус; SD выборочное. PPL улучшается на каждом корпусе в среднем, знак изменения NPMI зависит от корпуса.

Корпус	$\bar{g}$, %	SD, п.п.	Победы	$\overline{\Delta\text{NPMI}}$
BBC	6.53	2.47	9/9	+0.0322
20NG (4 кат.)	9.15	8.16	8/9	+0.0508
AG News	11.87	17.27	7/9	-0.0342
TechCrunch	6.41	1.84	9/9	-0.0657
PubMed	3.06	1.28	9/9	+0.0032

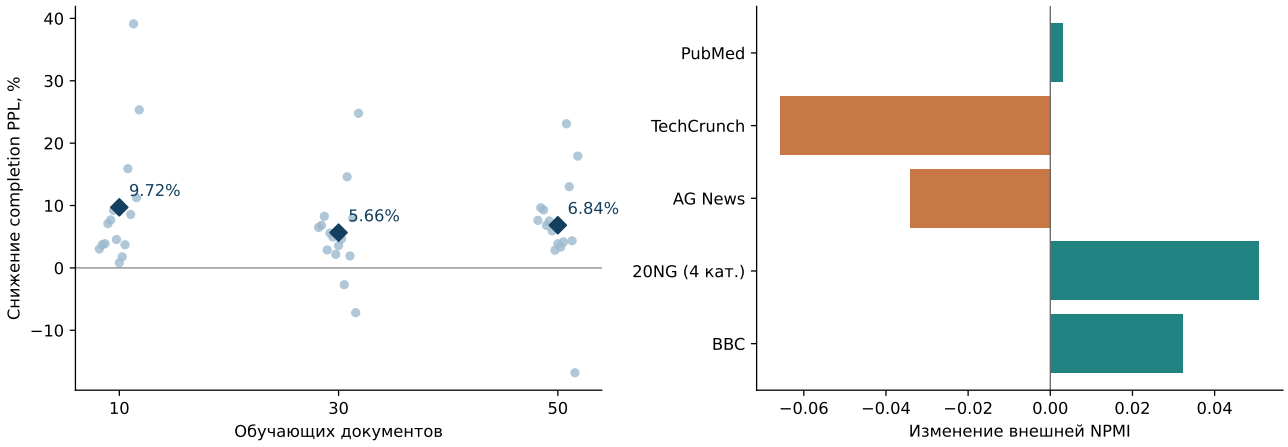


Рис. 1: Слева: парное снижение completion PPL по формуле (10) при разных размерах обучения; круги — 15 пар на размер, ромбы — средние. Разброс включает отрицательные эффекты, средний выигрыш максимален при десяти документах. Справа: среднее изменение внешней NPMI на девяти парах каждого корпуса; два корпуса имеют отрицательный эффект. Предсказательный выигрыш не означает систематического улучшения внешней когерентности.

На общей сетке из 27 пар полный метод даёт 5.3357% снижения completion PPL, только инициализация — 5.2676% (таблица 3). Разница равна приблизительно 0.068 процентного пункта; статистическое преимущество полного метода не установлено. Только KL даёт 1.1404%, переставленный учитель — 0.9025%. Наблюдения поддерживают полезность содержательной инициализации (H1 и H2), но не доказывают существенного дополнительного эффекта KL (H3). В исходной серии плотный KL также заметно уменьшает разреженность Φ; это издержка метода.

Таблица 3: Абляции на BBC, TechCrunch и PubMed: снижение completion PPL по формуле (10) относительно AARTM, 27 общих пар. Большая часть среднего эффекта сохраняется без KL.

Вариант	$\bar{g}$, %	SD, п.п.	Победы
Инициализация + KL	5.34	2.47	27/27
Только инициализация	5.27	2.63	27/27
Только KL	1.14	1.36	22/27
Переставленный учитель	0.90	1.21	20/27

3.6 arXiv и сопоставление с альтернативами

Training PMI AARTM+Q выше базовой AARTM во всех 20 парах (таблица 4, рисунок 2). Отношение средних PMI при $T = 500$ равно $0.5499/0.2709 \simeq 2.03$. Средний парный выигрыш training PPL при этом составляет 2.42%. При $T = 100$ training PPL улучшается лишь в трёх из четырёх пар; при остальных T — в четырёх. H4 поддерживается на сохранённой сетке, но из обучающих метрик не следует улучшение предсказания на новых arXiv-документах.

Таблица 4: arXiv: training PPL и training PMI, среднее $\pm$ выборочное SD по четырём seed. Формулы (6), (9), (10). PMI растёт при каждом числе тем; это оценка на обучающем корпусе.

T	PPL AARTM	PPL AARTM+Q	$\bar{g}$, %	PMI AARTM	PMI AARTM+Q
50	1050.45 ± 4.69	1045.22 ± 1.76	0.50	0.564 ± 0.009	0.679 ± 0.010
100	906.59 ± 0.73	903.42 ± 3.13	0.35	0.599 ± 0.025	0.751 ± 0.012
200	785.28 ± 2.36	778.75 ± 1.40	0.83	0.550 ± 0.072	0.761 ± 0.016
300	723.83 ± 2.55	717.19 ± 0.36	0.92	0.443 ± 0.049	0.710 ± 0.025
500	664.03 ± 1.97	647.99 ± 0.80	2.42	0.271 ± 0.028	0.550 ± 0.057

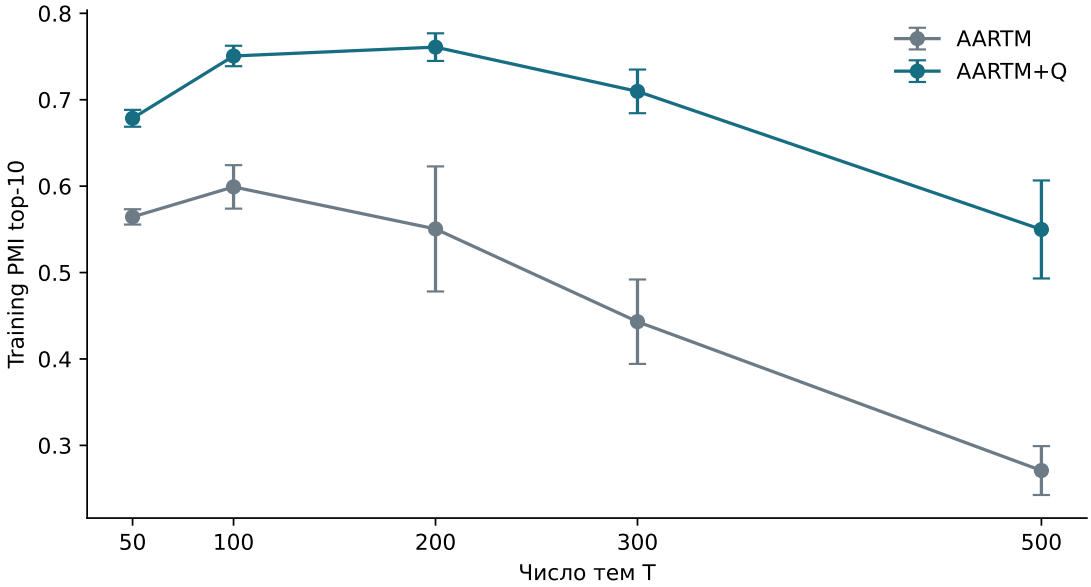


Рис. 2: Обучающая top-10 PMI по формуле (9) на 99 049 документах arXiv в зависимости от числа тем. Точки — средние четырёх seed, отрезки — выборочное SD. AARTM+Q выше базовой AARTM при каждом T; график не оценивает независимую семантическую интерпретируемость или качество на тесте.

Среди сохранённых конфигураций AARTM+Q имеет наибольшую training PMI относитель-

но FASTopic и CombinedTM+MiniLM при каждом T (таблица 5). Однако FASTopic обучен лишь 30 эпох. В дополнительном одиночном запуске $T = 100$, seed 42, переход к 200 эпохам повысил PMI с -5.7588 до -0.1984; это показывает существенное недообучение короткой серии. Для CombinedTM сходимость отдельно не проверена; его настройка отличается от авторской. Сильный штраф за нулевые пары также влияет на отрицательные PMI. Таблица не доказывает общего превосходства над полностью настроенными альтернативами.

Таблица 5: Training PMI по формуле (9), среднее $\pm$ выборочное SD. AARTM+Q выше в проверенных конфигурациях; FASTopic обучен 30 эпох, CombinedTM использует MiniLM.

T	AARTM+Q	FASTopic	CombinedTM+MiniLM
50	0.679 ± 0.010	0.009 ± 0.277	-3.887 ± 0.701
100	0.751 ± 0.012	-4.948 ± 0.791	-5.451 ± 0.539
200	0.761 ± 0.016	-6.653 ± 0.673	-6.298 ± 0.330
300	0.710 ± 0.025	-7.392 ± 0.458	-4.077 ± 0.560
500	0.550 ± 0.057	-8.062 ± 0.442	-1.019 ± 0.057

Таблица 6: Измеренное время, секунды, среднее $\pm$ выборочное SD. Для AARTM+Q учтены построение Q и обучение, для остальных моделей только обучение; первичное кодирование исключено. Единый сквозной выигрыш по скорости из таблицы не следует.

T	AARTM+Q	FASTopic	CombinedTM+MiniLM
50	192 ± 146	505 ± 8	1479 ± 368
100	420 ± 271	223 ± 112	2064 ± 16
200	632 ± 327	662 ± 71	2020 ± 148
300	1178 ± 458	958 ± 133	1861 ± 136
500	2321 ± 90	1754 ± 137	2525 ± 632

Время в таблице 6 имеет разные границы: AARTM+Q включает построение Q из готовых эмбеддингов и обучение, остальные модели — обучение. Подготовка данных, первичное кодирование и оценивание исключены; первичное время учителя полностью не зафиксировано. При $T = 500$ среднее AARTM+Q равно 2321.4 с, базовой AARTM — 2292.5 с. Для seed 43 и 45 в сравнительном CSV использованы повторные измерения времени; качество оставлено от исходных запусков. Поэтому ускорение полного процесса не установлено. Короткий запуск FASTopic при $T = 100$ особенно нельзя интерпретировать как преимущество по времени при одинаково достигнутом качестве.

3.7 Воспроизводимость и выводы

Материалы доступны в `https://github.com/Estanislavo/llm_tm_kl`. Таблицы и графики воспроизводятся командой `python code/reproduce_report.py` из опубликованных CSV. Скрипт проверяет число пар, совпадение характеристик данных внутри пар, отсутствие пересечений train/reference/test в 45 манифестах и контрольные суммы экспортированных файлов. Для минимального запуска модели приложены исходное ядро AARTM+Q и пример с искусственной коллекцией. Этот пример проверяет выполнение алгоритма и не добавляется к результатам реальных корпусов.

Полное независимое переобучение исторических серий имеет ограничение: revision исходных датасетов и контрольная сумма исходного Kaggle snapshot не сохранены. Опубликованные

манифесты позволяют сверять выбранные тексты, но не заменяют недостающие снимки. Полные веса и потоковая обучающая инфраструктура arXiv в этот комплект не входят. Публикация CSV обеспечивает повторный расчёт представленных результатов, а не точную реконструкцию всех исторических запусков.

Фиксированный контекстный учитель улучшает восстановление известных слов на проверенных малых коллекциях и обучающую PMI в arXiv-серии. Основную часть малого предсказательного эффекта объясняет инициализация. Общего роста внешней NPMI, обязательности KL и сквозного ускорения данные не подтверждают. Следующий содержательный эксперимент — отдельный arXiv test и сравнение полностью сошедшихся альтернатив при одинаковых границах измерения времени.

Использование ИИ. Инструменты генеративного ИИ использованы при подготовке текста, поиске литературы, написании кода пересчёта и проверке материалов. Численные результаты взяты из сохранённых запусков проекта; при подготовке этого комплекта полные экспериментальные серии заново не обучались.

Список литературы

[1] David M. Blei, Andrew Y. Ng, and Michael I. Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022, 2003.

[2] Konstantin Vorontsov and Anna Potapenko. Additive regularization of topic models. *Machine Learning*, 101:303–323, 2015.

[3] Adji B. Dieng, Francisco J. R. Ruiz, and David M. Blei. Topic modeling in embedding spaces. *Transactions of the Association for Computational Linguistics*, 8:439–453, 2020.

[4] Federico Bianchi, Silvia Terragni, and Dirk Hovy. Pre-training is a hot topic: Contextualized document embeddings improve topic coherence. In *Proceedings of ACL-IJCNLP: Short Papers*, pages 759–766, 2021.

[5] Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. FASTopic: Pretrained transformer is a fast, adaptive, stable, and transferable topic model. In *Advances in Neural Information Processing Systems*, volume 37, 2024.

[6] Zheng Fang, Yulan He, and Rob Procter. CWTM: Leveraging contextualized word embeddings from BERT for neural topic modeling. In *Proceedings of LREC-COLING*, pages 4273–4286, 2024.

[7] Dimo Angelov and Diana Inkpen. Topic modeling: Contextual token embeddings are all you need. In *Findings of EMNLP*, pages 13528–13539, 2024.

[8] Alexander Hoyle, Pranav Goel, and Philip Resnik. Improving neural topic models using knowledge distillation. In *Proceedings of EMNLP*, pages 1752–1771, 2020.

[9] SetFit. BBC News: Dataset card. Hugging Face, `https://huggingface.co/datasets/SetFit/bbc-news`. Accessed 2026-10-23.

[10] abhilash88. TechCrunch Articles: Dataset card. Hugging Face, `https://huggingface.co/datasets/abhilash88/techcrunch-articles`. Accessed 2026-10-23.

[11] Common Pile. PubMed: Article-text dataset card. Hugging Face, `https://huggingface.co/datasets/common-pile/pubmed`. Accessed 2026-10-23.

[12] fancyzhx. AG News: Dataset card. Hugging Face, `https://huggingface.co/datasets/fancyzhx/ag_news`. Accessed 2026-10-23.

[13] SetFit. 20 Newsgroups: Dataset card. Hugging Face, `https://huggingface.co/datasets/SetFit/20_newsgroups`. Accessed 2026-10-23.

[14] Cornell University. arXiv Dataset: Metadata snapshot. Kaggle, `https://www.kaggle.com/datasets/Cornell-University/arxiv`. Accessed 2026-10-23; original experiment snapshot revision not recorded.

[15] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019.

[16] Sentence Transformers. all-MiniLM-L6-v2: Model card. Hugging Face, `https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2`. Accessed 2026-10-23.

[17] Hanna M. Wallach, Iain Murray, Ruslan Salakhutdinov, and David Mimno. Evaluation methods for topic models. In *Proceedings of ICML*, 2009.

[18] David Newman, Jey Han Lau, Karl Grieser, and Timothy Baldwin. Automatic evaluation of topic coherence. In *Proceedings of NAACL-HLT*, pages 100–108, 2010.

[19] Gerlof Bouma. Normalized (pointwise) mutual information in collocation extraction. Author manuscript, 2009.