Фиксированный контекстный учитель для AARTM

Введение

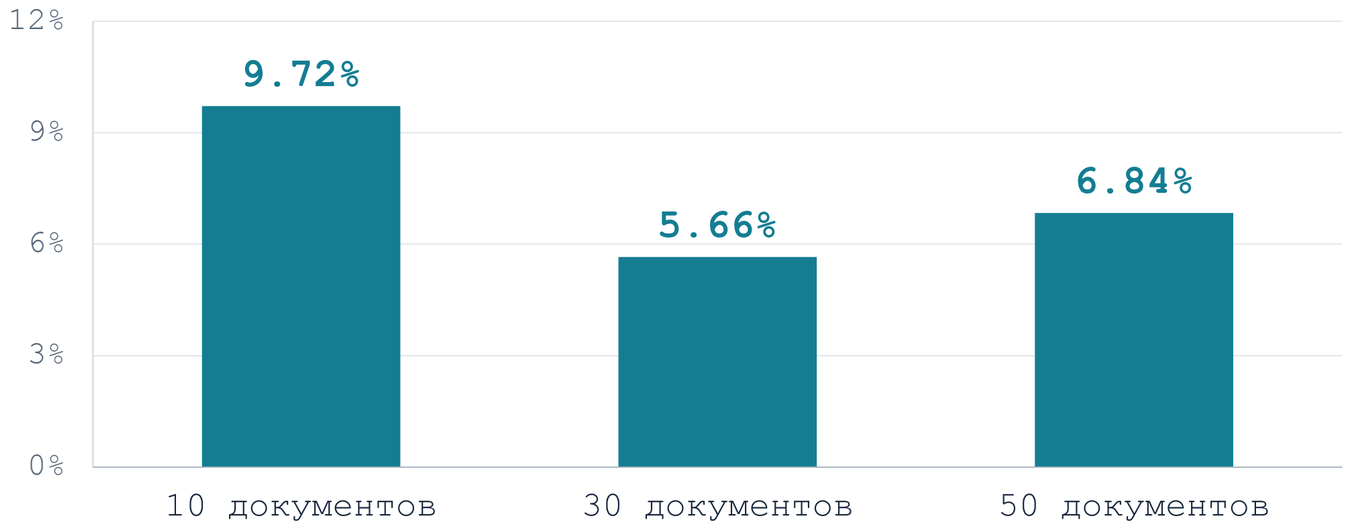
Тематические модели представляют коллекцию через распределения по словам и документам. AARTM дополняет аддитивную регуляризацию локальным контекстом: соседние слова влияют на назначение тем. Однако на малых коллекциях модели не хватает данных для выявления семантических связей. Контекстный учитель на основе предобученной языковой модели может предоставить такую информацию для малых коллекций и повысить качество модели на больших корпусах.

Мы исследуем, может ли эта информация улучшить существующую тематическую модель с вниманием без дообучения внешнего энкодера. KL-регуляризатор согласует распределения тем учителя и тематической модели. Ниже описано построение распределений учителя. Хотя идея может распространяться на другие тематические модели, наши эксперименты посвящены AARTM.

Наш вклад: (i) простой способ построения целевых распределений для слов словаря из контекстных эмбеддингов фрагментов, (ii) обучение существующей тематической модели с KL-регуляризацией по этим целям, (iii) наивысшая PMI на обучающей выборке среди сравниваемых моделей arXiv при всех пяти значениях числа тем.

Насколько учитель улучшает восстановление слов?

Снижение document-completion PPL относительно AARTM, %



−7,40% PPL в среднем · 42/45 выигранных пар

5 корпусов: BBC, TechCrunch, PubMed, AG News, 20NG (4 категории) 10 / 30 / 50 обучающих документов, 3 seed. Проценты усреднены по парам.

Учитель Q = q(t|w) задаёт инициализацию и KL-согласование